

논문 2019-14-31

다중 이벤트 센서 기반 스마트 홈에서 사람 행동 분류를 위한 효율적 의사결정평면 생성기법 (Efficient Hyperplane Generation Techniques for Human Activity Classification in Multiple-Event Sensors Based Smart Home)

장 준 서, 김 보 국, 문 창 일, 이 도 현, 곽 준 호, 박 대 진, 정 유 수*
(Juneseo Chang, Boguk Kim, Changil Mun, Dohyun Lee, Junho Kwak, Daejin Park, Yoosoo Jeong)

Abstract : In this paper, we propose an efficient hyperplane generation technique to classify human activity from combination of events and sequence information obtained from multiple-event sensors. By generating hyperplane efficiently, our machine learning algorithm classify with less memory and run time than the LSVM (Linear Support Vector Machine) for embedded system. Because the fact that light weight and high speed algorithm is one of the most critical issue in the IoT, the study can be applied to smart home to predict human activity and provide related services. Our approach is based on reducing numbers of hyperplanes and utilizing robust string comparing algorithm. The proposed method results in reduction of memory consumption compared to the conventional ML (Machine Learning) algorithms; 252 times to LSVM and 34,033 times to LSTM (Long Short-Term Memory), although accuracy is decreased slightly. Thus our method showed outstanding performance on accuracy per hyperplane; 240 times to LSVM and 30,520 times to LSTM. The binarized image is then divided into groups, where each groups are converted to binary number, in order to reduce the number of comparison done in runtime process. The binary numbers are then converted to string. The test data is evaluated by converting to string and measuring similarity between hyperplanes using Levenshtein algorithm, which is a robust dynamic string comparing algorithm. This technique reduces runtime and enables the proposed algorithm to become 27% faster than LSVM, and 90% faster than LSTM.

Keywords : Smart home, IoT, Embedded machine learning, Light weight, High speed

1. 서론 및 관련 연구

오늘날 딥러닝 (Deep learning)을 필두로 다양한 분야에 머신러닝을 적용하여 인간이 수행하는 기능을 대체하거나, 인간에게 보다 나은 편의를 제

공하기 위한 IoT제품이 많이 출시되고 각광받고 있다. 특히 인공지능 스피커, 스마트 시계 등과 같이 사람으로부터 획득되는 신호를 이용하여 사람에게 적절한 피드백 (Feedback)을 줄 수 있는 사물-사람 간 서비스가 주를 이루고 있다.

한편 사람의 행동 패턴 역시 사람으로부터 획득되는 중요한 신호 중 하나이기 때문에 사람의 행동을 분류하여 감시 및 관리하기 위한 사람 행동 분류 관련 연구가 활발히 수행되고 있다.

대표적으로 웨어러블 기기 (Wearable device)의 경우 사람에게 직접 부착되어 직접적으로 측정할 수 있는 ECG (Electrocardiography), GPS (Global positioning system), Accelerometer 등의 신호를 이용하여 사용자의 삶의 질을 향상시키기 위한 행동 분류 연구가 수행되고 있다 [1, 2]. 한편 머신러

*Corresponding Author (ysjung@ee.knu.ac.kr)

Received: Sep. 6, 2019, Revised: Sep. 18, 2019,

Accepted: Sep. 27, 2019.

J. Chang, B. Kim, C. Mun, D. Lee: Daegu Science High School.

Y. Jeong, J. Kwak, D. Park: Kyungpook National University.

※ 본 연구는 대구과학고등학교 2학년 자율연구 프로그램의 지원을 받아 진행함.

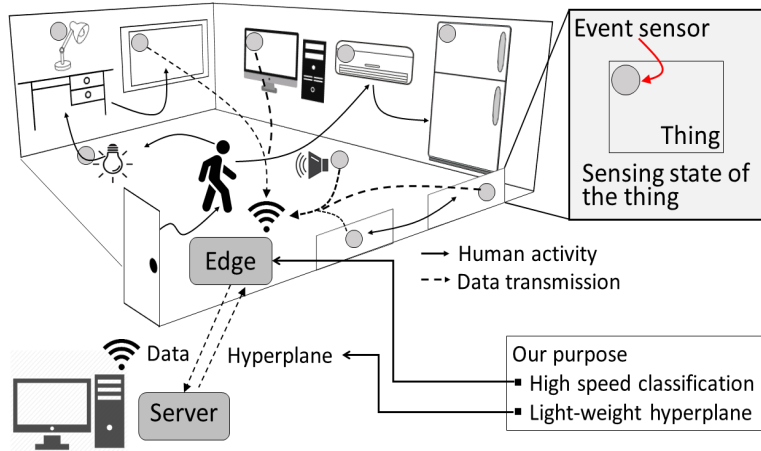


그림 1. 스마트 홈을 위한 사람 행동 분류 시스템 개념도

Fig. 1 Conceptualization of human activity recognition system for smart home

닝 적용에 있어 데이터양이 주요 이슈이기 때문에 다중센서로부터 획득된 많은 양의 데이터를 이용하여 행동 분류의 정확도를 높이기 위한 연구 또한 수행되고 있다 [3].

웨어러블 기기처럼 사람으로부터 직접 신호를 획득하는 기법 대신 리모트 센싱 (Remote sensing) 하여 사람의 행동을 분류하기 위한 연구 역시 활발히 수행되고 있다. 특히 카메라를 이용하여 사람을 촬영 및 행동을 분류하기 위해 2차원 정보만을 획득할 수 있는 RGB카메라를 이용하는 추세에서 보다 많은 양의 데이터를 획득할 수 있는 Depth카메라에 기반 하여 행동 분류의 정확도를 높이기 위한 연구가 주를 이루고 있다 [4].

또한, 지능형 CCTV를 이용하여 행동 분류 기반 방법, 방화 등을 검출하기 위한 연구가 빅데이터 (Big data) 기반으로 수행되고 있다 [5].

최근 스마트 홈 (Smart home)은 IoT 및 인공지능의 발전과 더불어 인구 고령화, 장애인 복지 등의 사회문제를 해결할 수 있는 솔루션 (Solution)으로 논의되고 있다 [6]. 하지만 실제 생활에 적용 가능한 어플리케이션에 관한 연구는 미진한 상황이다.

따라서 본 논문에서는 차후 스마트 홈에 실제 적용 가능성을 타진하기 위해 빅데이터를 기반으로 특정 공간 내 다양한 IoT 기기에 부착된 센서들을 이용한 사람의 행동 패턴을 분류 및 예측하는 기법을 연구한다.

본 논문에서 제안하는 스마트 홈을 위한 다중 이벤트 센서 기반 사람 행동 분류 시스템 개념도를

그림 1과 같이 나타내었다. 각 사물에 사물의 상태를 센싱 (Sensing)할 수 있는 센서를 부착하여 해당 사물들의 상태에 대한 신호 조합과 순서정보를 엣지 (Edge)에서 획득 및 서버로 전송한다. 서버에서 해당 데이터를 이용하여 학습 후, 학습 결과인 의사결정 평면 (Hyperplane)을 엣지로 전송하여 실시간으로 사람의 행동 패턴을 분류한다.

이와 같은 연구는 차후 분류된 사람의 행동패턴에 적절한 서비스를 제공하기 위해 이용될 수 있다. 예를 들어 그림 1과 같은 시스템 하에서 책상 조명이 꺼지고 스피커가 켜질 경우 사람이 공부 후 음악을 들으며 쉬는 상태로 분류할 수 있으며, 현관문이 열리고 TV를 켜다면 귀가 후 쉬는 상태로 분류하는 등, 각 사람의 행동패턴에 대해 관련 서비스를 달리 제공할 수 있다.

해당 시스템 하에서, 비교적 약한 컴퓨팅 파워 (Computing power)를 가지는 엣지에서 동작하는 알고리즘은 다음과 같은 조건을 요구한다. 첫 번째 조건은 저전력 (Low power)에서 동작할 수 있는 에너지 효율적 (Energy efficient) 알고리즘이어야 한다. 두 번째는 적은 의사결정평면 메모리 (Memory)에서 동작할 수 있는 경량화 (Light weight)된 알고리즘이어야 한다. 세 번째는 약한 컴퓨팅 파워 하에서도 실시간으로 처리될 수 있는 고속화된 알고리즘이어야 한다.

따라서 본 논문에서는 저전력 알고리즘 연구를 위해 다중 이벤트 센서 기반 사람의 행동 패턴을 분류함에 있어 이벤트 중심 샘플링 (Event-driven

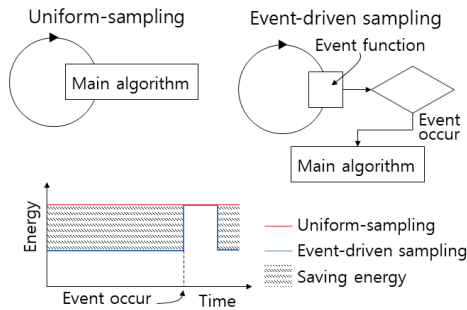


그림 2. 이벤트 중심 샘플링 기반 신호처리의 전력효율

Fig. 2 Energy efficiency of event-driven sampling-based signal processing

sampling)기반 신호를 신호처리 대상으로 가정한다. 일반적인 데이터 취득 및 신호처리 기법은 균일-샘플링 (Uniform-sampling)에 기반한다. 균일-샘플링 기법은 예상되는 가장 높은 주파수에 의해 결정된 빈도수를 고정적으로 모든 신호에 대해 적용한다. 하지만 원신호가 낮은 주파수인 상태일 때 높은 빈도수로의 샘플링은 불필요하기 때문에 전력 낭비가 있다 [7]. 최근 기존의 균일-샘플링의 전력 비효율성을 회피하며 대상 신호를 샘플링하기 위한 기법으로 이벤트 기반 샘플링이 활발히 연구되고 있다 [8, 9].

한편, 경량화된 머신러닝 (Machine learning) 알고리즘이 되기 위해 자동으로 의사결정 평면을 생성하는 기존 방법 대신 사람이 직접 데이터 특성을 고려하여 의사결정평면 메모리 대비 정확도 효율적인 의사결정 평면 생성 기법을 제안한다.

마지막으로 분류 과정을 고속화하기 위해 의사결정 평면과 입력 신호의 유사도 측정을 수행함에 있어 고속 문자열 비교 알고리즘을 이용한다.

본 논문의 구성은 다음과 같다. 2장에서는 제안한 연구의 문제 정의 과정에 대해 서술하고, 3장에서는 제안하는 구조를 소개한다. 그리고 4장에서는 실험을 통해 제시하는 기법의 타당성을 입증하며, 마지막으로 5장에서 결론을 맺는다.

II. Problem definition

1. 문제 정의

본 논문은 이진화 (Binarization)된 MNIST (Modified National Institute of Standards and Technology) 데이터의 각 열을 사람의 행동으로부

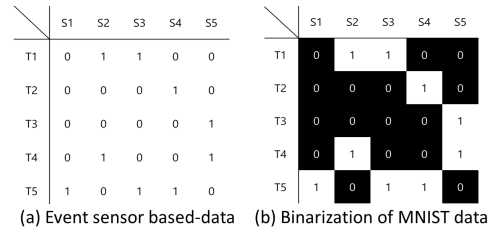


그림 3. 이벤트 센서 기반 신호 패턴과 이진화된 MNIST 데이터의 패턴

Fig. 3 Event sensor data pattern and binarization of MNIST data pattern

터 발생한 각 이벤트 센서로부터 획득된 신호로 가정하고, LSVM의 의사결정 평면 생성과정 대신 효율적 의사결정 평면 생성 기법을 제안함으로써 에너지 효율이 있는 이벤트 중심 샘플링 기반 경량화된 학습기법과 고속화된 분류 기법을 연구한다.

2. 가정 : 이진화된 MNIST의 열데이터를 이벤트 중심 샘플링된 신호로 가정

IoT기반 연구에 있어 전력 효율은 메인 이슈이며 [10] 이벤트 기반 샘플링은 그림 2와 같이 일반적인 균일-샘플링과 달리 비균일 샘플링으로 대상 신호의 상태에 따라 적응적으로 샘플링 주기가 조절되기 때문에 전력 효율이 높다 [7]. 때문에 본 논문에서는 사람의 행동 패턴을 분류함에 있어 이벤트 기반 샘플링을 가정하여 이벤트 중심 샘플링 기반 사람의 행동 분류를 위한 머신러닝을 연구했다.

본 논문에서 가정한 이벤트 기반 센서는 On-off 이벤트만 발생시키는 센서로서 각 센서 S_1, S_2, \dots 로부터 획득되는 신호는 시점 T_1, T_2, \dots 에 대해 그림 3. (a)와 같이 이벤트 발생여부들의 조합으로 구성된 이진 신호의 행태를 가진다. 때문에 많은 양의 데이터를 고려하기 위해 다중 이벤트 센서 기반 사람 행동 분류 연구를 수행함에 있어 MNIST데이터를 그림 3. (b)와 같이 이진화하여 각 열을 하나의 센서로부터 획득되는 데이터로 보고, 이진화된 하나의 영상이 사람의 행동으로 발생하는 이벤트 센서 신호의 조합으로 가정하여, 이진화된 MNIST 데이터의 숫자 분류를 연구함으로써 다중 이벤트 센서 기반 사람 행동 분류 연구를 수행하였다.

3. Baseline project : LSVM

LSVM은 요구되는 계산량과 의사결정평면 메모리가 비교적 작기 때문에 임베디드 환경에서 널리

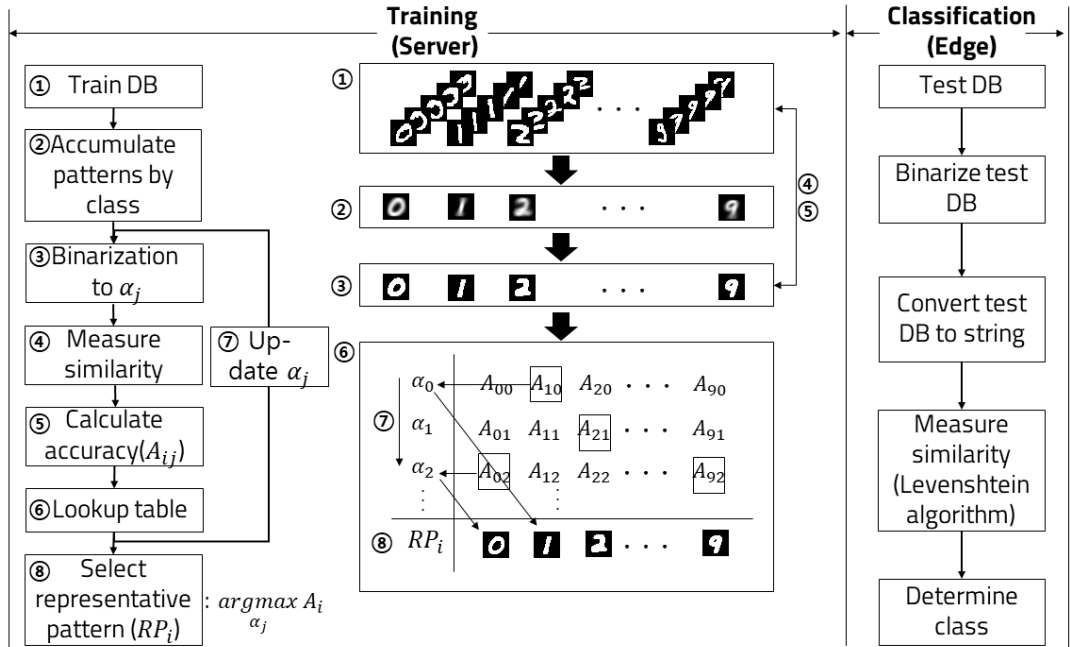


그림 4. 제안 알고리즘 흐름도
Fig. 4 Flow chart of proposed algorithm

활용되는 머신러닝 기법중 하나이다 [11, 12]. 본 논문에서는 이진화된 MNIST 데이터를 LSVM을 이용하여 분류하는 기법을 baseline으로 선정하고 baseline 보다 경량화된 머신러닝 알고리즘을 연구하였다. 하지만 LSVM의 경우 선형 함수만을 이용하여 의미론 (Semantics)없이 의사결정 평면을 형성하기 때문에 비효율적이다.

따라서 본 논문에서는 이벤트 중심 샘플링에 기반하여 LSVM이 가지고 있는 비효율성을 개선하기 위해 사람이 직접 데이터 특성에 맞게 의사결정 평면을 생성하는 기법을 제안한다.

한편 LSVM의 분류 과정은 테스트 샘플의 특징 벡터와 의사결정 평면과의 거리를 계산하는 선형 조합을 계산하는 형태로 수행된다. 이는 학습 과정에서 점과 직선사이의 거리를 매개변수 (Parameter)로 이용하는 LSVM의 연산 방법상 변형이 불가능하기 때문에 고속화에 한계가 있다.

본 논문에서는 의미론을 가지고 사람이 직접 생성한 의사결정 평면을 이용하여 분류과정에 고속 문자열 비교 알고리즘을 적용함으로써 분류 과정의 속도를 개선한다.

III. 제안 알고리즘

그림 4는 제안 알고리즘 흐름도를 나타낸다. 서버에서 경량화된 의사결정 평면을 계산하기 위한 학습 알고리즘을 수행하고 생성된 의사결정 평면을 엣지에서 전송받아 분류 알고리즘을 수행한다.

1. Training (Server) - 경량화된 의사결정 평면 생성 기법

본 논문에서는 이벤트 중심 샘플링기반 머신러닝 알고리즘을 연구함에 있어 데이터 특성에 맞는 의사결정 평면을 생성하기 위해 클래스별 대표 패턴을 생성한다.

각 클래스 i 에 대해 대표 패턴 RP_i 을 생성하기 위한 첫 번째 단계는 학습 데이터 (그림 4. ①)를 시점별로 이벤트 발생 횟수를 누적한, 픽셀 (Pixel) 별 이벤트 발생 누적 빈도수 패턴 (그림 4. ②)을 생성하는 것이다.

픽셀별 이벤트 발생 누적 빈도수 영상 R_k 은 i 클래스 내 0과 1로 이진화된 MNIST 학습 영상 BP_k 를 누적하여 식 (1)과 같이 구할 수 있다.

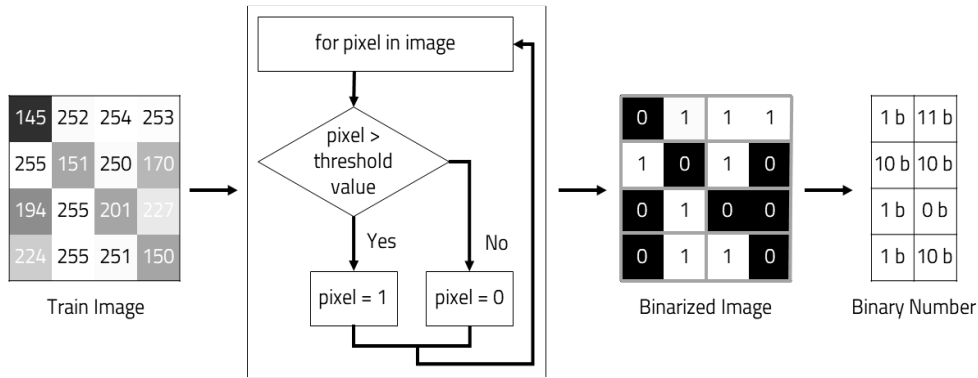


그림 5. 이미지 양자화 및 이진수로의 변환 과정

Fig. 5 Image quantization and conversion to binary number

$$R_i(x, y) = \sum_{k=1,2,\dots}^{N_i} BP_k(x, y) \quad (1)$$

여기서 N_i 는 학습 데이터 중 i 클래스인 영상의 개수를 의미하며 (x, y) 는 각 영상 내 좌표를 의미한다.

픽셀 별 이벤트 발생 빈도수 패턴 R_i 은 데이터에 존재하는 인라이어 (inlier)와 아웃라이어 (outlier)에 대한 구분없이 모두 같은 중요도로 생성되기 때문에 인라이어를 충분히 대표할 수 없다. 아웃라이어는 클래스를 구성하는 이미지에서 나타나는 횟수가 적고 나타나는 픽셀의 위치도 불규칙하다는 특성을 가지고 있기 때문이다.

따라서 인라이어의 특성을 잘 대표할 수 있는 대표패턴을 생성하기 위해 인라이어와 아웃라이어를 구분할 수 있는 문턱치 (Threshold) α_j 를 구한다. 여기서 j 은 반복횟수를 의미 한다.

α_j 는 R_i 의 각 픽셀이 인라이어에 포함 여부를 결정하는 역할을 한다. α_j 를 통해 R_i 를 이진화된 데이터로 변환한 다음, 데이터의 특성을 보존하면서 데이터의 크기를 줄이기 위해 R_i 의 각 행을 2개의 구간으로 나누어 각각의 구간을 이진수로 변환한다. 해당 문턱치 적용 과정과 이진수로의 변환 과정을 도식화하여 그림 5와 같이 나타내었다.

문턱치 역할을 하는 α_j 를 클래스 별로 적절히 선택함으로써 빈도가 낮은 아웃라이어 데이터의 가중치는 줄이고 빈도가 높은 인라이어의 가중치는 높여 표준에 가까운 의사결정 평면을 얻을 수 있으며, 각 행을 이진수로 변환하는 과정을 통해 의사결정 평면의 특성을 보존하면서 크기를 줄일 수 있

기 때문에 적은 의사결정 평면으로도 높은 정확도와 빠른 유사도 측정을 달성할 수 있다.

본 논문에서는 i 클래스를 대표할 수 있는 대표 패턴 RP_i 를 생성하기 위한 적절한 α_j 을 선택 방법으로 그림 4. ⑥과 같이 룩업테이블 (Look up table)을 생성하여 α_j 를 변화시킴에 따라 클래스별 정확도 A_{ij} 를 계산 후 최대의 정확도를 가지는 α_j 를 선택하는 방법을 적용하였다. 정확도 계산을 위한 유사도 계산 (그림 4. ④)은 다음 장에서 자세히 기술한다.

2. Classification (Edge) - Levenshtein 기법 기반 유사도 측정 고속화

한편, 저성능 임베디드 시스템에서는 의사결정평면 메모리 사용량뿐만 아니라 알고리즘의 수행속도 또한 소비 전력에 영향을 주는 중요한 이슈이다. 따라서 본 논문에서는 LSVM의 예측과정인 선형조합 연산에 대응되는 대표패턴 RP_i 과 실험패턴 BP_k 의 유사도 측정 과정을 고속 문자열 비교 알고리즘을 이용함으로써 예측과정을 고속화 한다. 여기서 실험 패턴 BP_k 는 이진화된 다음 RP_i 와 같이 각 행을 2개의 구간으로 나누어 이진수로 변환한 MNIST의 실험 데이터이다.

고속 문자열 처리 알고리즘을 이용하기 위해 RP_i 와 BP_k 를 문자열로 변환한다. RP_i 와 입력 패턴 모두 이진수로 이루어진 데이터이므로 비교의 편의성을 위해 십진법의 정수로 변환한다. 변환된 십진수를 하나의 문자로 가정해 RP_i 와 BP_k 를 문자열로 변환한다. 문자열로 변환된 패턴에 문자열간 유사도

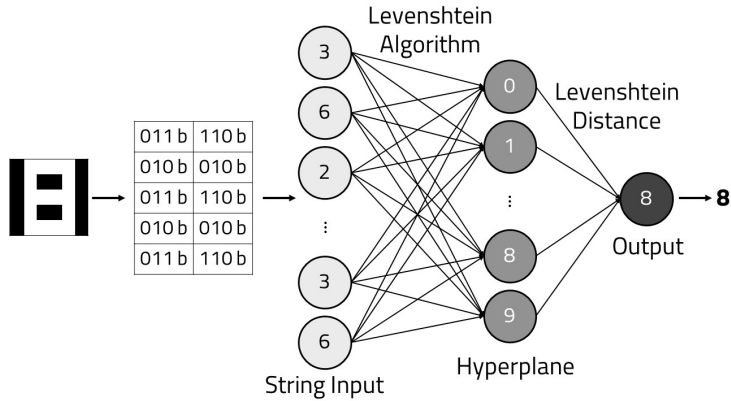


그림 6. Levenshtein 알고리즘을 이용한 유사도 측정 기법

Fig. 6 Similarity calculation method using Levenshtein algorithm

를 판단하기 위한 Levenshtein 알고리즘을 적용한다.

Levenshtein 알고리즘은 유사도를 계산하고자 하는 두 문자열 간의 가장 작은 수정거리 (Edit Distance)를 구하는 알고리즘이다. 이때 수정거리는 두 문자열 간의 유사성을 나타내는 척도로써 한 문자열에서 다른 문자열로 바꾸는데 몇 번의 삽입, 제거, 교체의 과정이 필요한지를 나타낸다.

$$lev_{a,b}(m,n) = \begin{cases} \max(m,n), & \min(m,n) = 0 \\ \min \begin{cases} lev_{a,b}(m-1,n) + 1 \\ lev_{a,b}(m,n-1) + 1 \\ lev_{a,b}(m-1,n-1) + 1_{(a_m \neq b_n)} \end{cases} & , otherwise \end{cases} \quad (2)$$

두 문자열 a 와 b 간의 Levenshtein 거리는 두 문자열을 같은 문자열로 만들기 위해 필요한 최소 수정 거리이다. 문자열 a 의 m 번째, 문자열 b 의 n 번째 문자까지의 Levenshtein 거리 $lev_{a,b}(m,n)$ 는 수식 (2)와 같이 계산할 수 있다. a 의 m 번째 문자 a_m 과 b 의 n 번째 문자 b_n 에 대해 $1_{(a_m \neq b_n)}$ 는 $a_m = b_n$ 일 때 0의 값을 가지고 $a_m \neq b_n$ 일 경우에 1의 값을 가지는 지시 함수이다. 수식 (2)에서 m 이나 n 이 0이라면 $\max(m,n)$ 을 반환하고 그 외의 경우에는 a_m 의 m 번째 원소를 삭제한 경우, a_m 에 b_n 의 n 번째 문자를 삽입한 경우, a_m 의 m 번째 원소를 b_n 의 n 번째 원소로 교체한 경우 중 최소 수정거리를 반환한다.

본 논문에서는 그림 6와 같이 Levenshtein 알고리즘을 이용하여 입력패턴 BP_k 과 의사결정 평면에

대응되는 대표패턴 RP_i 와의 유사도를 측정하여 가장 높은 유사도를 가지는 RP_i 의 클래스를 계산하여 BP_k 의 클래스를 분류한다. 이때 BP_k 의 분류결과 \hat{i} 는 식 (3)과 같이 구할 수 있다.

$$\hat{i} = \operatorname{argmin}(lev_{RP_i, BP_k}(M, N)) \quad (3)$$

여기서 M 과 N 은 각각 RP_i 와 BP_k 의 길이이다.

Levenshtein 알고리즘은 동적 계획법 알고리즘으로 최적화 [13] 하여 빠른 속도로 두 데이터의 유사도를 계산한다.

IV. 시뮬레이션 및 결과

본 논문에서 제안한 머신러닝 알고리즘을 구현하여 실험 및 LSVM과 LSTM과 성능 비교 실험을 수행하였다. 실험을 위해 제안기법은 C++을 이용하여 구현하였고 LSVM의 경우 Opencv 3.4.0을 이용하였으며 LSTM은 tensorflow 1.14.0의 BasicRNNCell을 128개의 유닛으로 구현하여 사용하였다. 실험을 위해 사용된 컴퓨터의 CPU는 2.5ghz intel core i7 RAM은 DDR3 16GB 이다.

실험 데이터는 MNIST 데이터셋이며 이중 학습 데이터는 6000개, 검증 데이터는 1000개를 선별하여 실험에 사용하였다. 이벤트 중심 샘플링을 가정하기 위해 MNIST 이미지의 각각의 픽셀 값에 대하여 문턱치 값을 200으로 설정하여 이진화한 후 실험을 진행하였다.

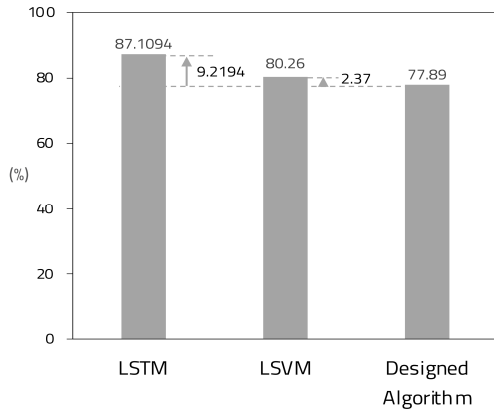


그림 7. 머신러닝 알고리즘에 따른 정확도 비교
Fig. 7 Accuracy according to different machine learning algorithms

1. 의사결정 평면의 효율성 비교 실험

의사결정 평면의 효율성을 나타내는 검증프로토콜 (Validation protocol)로 의사결정 평면의 메모리÷정확도 비교 하였다. 해당 검증을 위해 앞서 아래와 같이 각 기법의 정확도 및 의사결정 평면의 메모리 사용량을 비교하였다.

1.1 정확도 비교

적용한 머신러닝 알고리즘에 따른 정확도를 비교하여 그림 7과 같이 나타내었다. LSVM의 정확도는 80.26%, LSTM의 정확도는 87.1094%, 제안한 머신러닝 알고리즘의 정확도는 77.89%로 나타났다. 각 알고리즘의 정확도를 시각적으로 비교하는 그래프를 그림 7로 나타내었다. 정확도는 LSTM, LSVM, 제안한 머신러닝 알고리즘 순으로 높았다.

1.2 의사결정평면 메모리 사용량 비교

본 논문에서 제안한 머신러닝 알고리즘과 기존의 LSVM과 LSTM으로 구현한 머신러닝 알고리즘의 의사결정평면 메모리 사용량을 그림 8로 나타내었다. 각각의 머신러닝 알고리즘의 의사결정 평면의 메모리 사용량은 식 (4)로 계산하였다. 이때 M 은 의사결정평면 메모리 사용량, N 은 사용된 의사결정 평면개수, T 는 사용한 데이터 형의 크기를 의미하며 $1M$ 은 1byte 크기 의사결정 평면 1개의 의사결정평면 메모리 사용량을 나타낸다.

$$M = N \times T \quad (4)$$

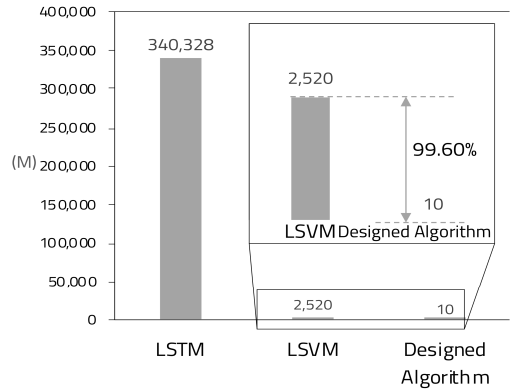


그림 8. 머신러닝 알고리즘에 따른 의사결정평면 메모리 사용량 비교

Fig. 8 Memory usage according to different machine learning algorithms

본 논문에서 제안한 머신러닝 알고리즘은 대표 패턴 RP_i 를 클래스 별로 생성하여 의사결정 평면으로 이용하므로 10개의 클래스를 가진 MNIST 데이터에 대해 10개의 char형 의사결정 평면이 사용된다. 즉 제안 알고리즘의 의사결정 평면의 의사결정평면 메모리 사용량은 $10M(10N \times 1T)$ 이다.

Baseline project로 수행한 LSVM의 경우 45개의 의사결정 평면을 사용하였다. 때문에 LSVM이 사용한 의사결정평면 메모리량은 $2,520M(45N \times 56T)$ 이다. 그리고 tensorflow로 구현한 LSTM의 경우 의사결정 평면 관련 의사결정평면 메모리 사용량이 $340,328M$ 으로 측정되었다. 각 알고리즘별 의사결정평면 메모리 사용량을 그림 8과 같이 그래프로 나타내어 비교하였다. 제안된 머신러닝 알고리즘을 사용할 경우 알고리즘이 사용하는 의사결정 평면수가 적어 의사결정평면 메모리 사용량이 LSTM과 LSVM에 비해 90% 이상 감소하는 것을 확인하였다.

1.3 검증 결과

계산한 정확도와 의사결정평면 메모리 사용량을 이용하여 의사결정 평면의 효율성을 나타내는 검증 프로토콜인 정확도와 의사결정평면 메모리 사용량의 비를 계산하여 그림 9와 같이 나타내었다.

제안 기법의 분류 정확도가 기존 기법들에 비해 소폭 감소하였지만 의사결정평면 효율이 LSVM에 비해 252배 LSTM에 비해 34,033배 높음을 확인하였다.

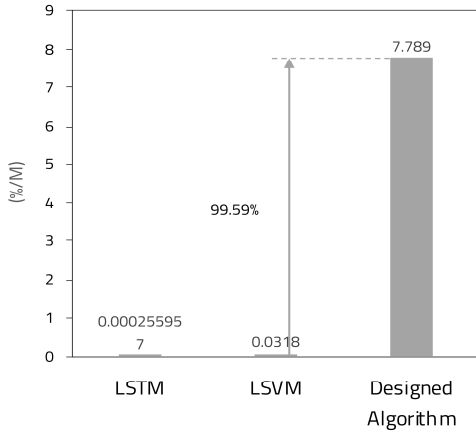


그림 9. 머신러닝 알고리즘에 따른
정확도÷의사결정평면 메모리 비교 그래프

Fig. 9 Accuracy÷memory according to different machine learning algorithms

2. 고속화 검증 실험

그림 10은 본 논문에서 제안한 머신러닝 알고리즘과 LSVM, LSTM 머신러닝 알고리즘의 실행시간을 비교한 그래프이다. 제안한 머신러닝 알고리즘은 LSTM에 비해 실행시간을 획기적으로 단축했으며 LSVM과 비교했을 때에도 실행시간이 27% 감소하는 것으로 나타났다.

V. 결 론

본 논문에서는 이벤트 센서로부터 획득된 신호에 머신러닝을 적용함에 있어 의사결정평면 메모리 사용량과 실행시간 감소에 목적을 두고 효율적 의사결정 평면 생성 기법을 제안하였다. 빅데이터를 대상으로 해당 연구를 진행하기 위해 이진화된 MNIST 데이터를 이벤트 센서로부터 획득된 신호로 가정하고 연구를 수행하였다. 10개의 클래스를 가지고 있는 MNIST 데이터 셋에 대해 각 이미지를 구성하는 픽셀들이 데이터셋에서 포함된 횟수의 평균값을 산출하고 산출된 평균값을 특정한 문턱치를 기준으로 양자화하는 방식으로 10개의 의사결정평면을 구성하였다. 생성된 의사결정 평면의 특성을 유지하면서 유사도 측정의 고속화를 위해 생성된 의사결정 평면의 행을 2개의 구간으로 나누어 이진수로 변환하였고, 변환된 이진수들을 십진수의 정수로 된 문자열의 형태로 변환하였다. 테스트 데이터

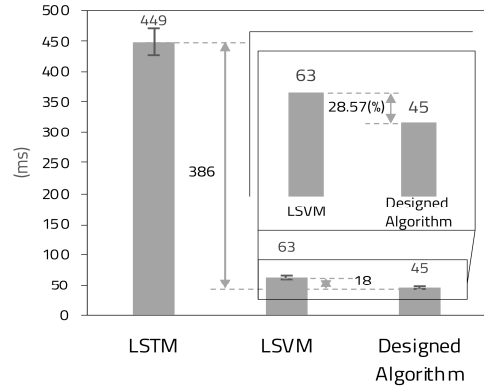


그림 10. 머신러닝 알고리즘에 따른 실행 시간 비교
그래프

Fig. 10 Run time according to different machine learning algorithms

또한 양자화한 후 이진수로 표현하고 십진수의 정수로 이루어진 문자열로 변환하여 동적 계획법 문자열 비교 알고리즘인 Levenshtein 알고리즘을 이용하여 테스트 데이터와 의사결정 평면 데이터 사이의 유사도를 판별하였다. 제안 기법으로 생성된 의사결정평면의 효율성과 수행속도 개선을 검증하기 위해 기존의 머신러닝 기법인 LSTM 및 LSVM과 비교하는 실험을 수행하였다. 그 결과 분류 정확도는 LSTM에 비해 9.2% LSVM에 비해 2.4%감소하였지만 의사결정 평면의 효율성 프로토콜 (정확도÷의사결정평면 메모리)의 경우 240배 개선되었으며 수행 속도 역시 각 방법에 비해 27%이상 개선되었다.

정확도는 소폭 감소했지만 경량화 및 고속화된 제안 알고리즘은 보다 저성능의 임베디드 시스템에 적용하여 차후 스마트 홈에서 사람의 행동을 예측 및 관련 서비스를 제공하기 위해 이용될 수 있다.

References

- [1] P. Casale, O. Pujol, P. Radeva, "Human Activity Recognition from Accelerometer Data Using a Wearable Device," Proceedings of Pattern Recognition and Image Analysis, pp. 289-296, 2011.
- [2] T. Fujimoto, H. Nakajima, N. Tsuchiya, H.

- Marukawa, K. Kuramoto, S. Kobashi, Y. Hata, "Wearable Human Activity Recognition by Electrocardiograph and Accelerometer," Proceedings of 2013 IEEE 43rd International Symposium on Multiple-Valued Logic, pp. 12-17, 2013.
- [3] S. Shin, J. Cha, "Human Activity Recognition System Using Multimodal Sensor and Deep Learning Based on LSTM," Journal of Transactions of the Korean Society of Mechanical Engineers, Vol. 42, No. 2, pp. 111-121, 2018 (in Korean).
- [4] O. Ann, B. Lau, "Human Activity Recognition: A Review," Proceedings of 4th IEEE International Conference on Control System, Computing and Engineering, pp. 389-393, 2015.
- [5] S. Ke, H. Thuc, Y. Lee, N. Hwang, J. Yoo, K. Choi, "A Review on Video-Based Human Activity Recognition," Computers, Vol. 2, No. 2, pp. 88-131, 2013.
- [6] M. Chan, D. Estève, C. Escriba, E. Campo, "A Review of Smart Homes—Present State and Future Challenges," Journal of Computer Methods and Programs in Biomedicine, Vol 91, No. 1, pp. 55-81, 2008.
- [7] Y. Tsvividis, "Event-Driven Data Acquisition and Digital Signal Processing-A Tutorial," Journal of IEEE Transactions on Circuits and Systems, Vol. 57, No. 8, pp. 577-581, 2010.
- [8] A. Konak, A. Smith, S. Kulturel-Konak, "New Event-driven Sampling Techniques for Network Reliability Estimation," Proceedings of the 2004 Winter Simulation Conference, Vol. 1, pp. 231, 2004.
- [9] N. Persson, Event Based Sampling with Application to Spectral Estimation, Division of Control & Communication, Department of Electrical Engineering, Linköpings universitet, 2002.
- [10] B. Karg, S. Lucia, "Towards Low-energy, Low-cost and High-performance IoT-based Operation of Interconnected Systems," Proceedings of 2018 IEEE 4th World Forum on Internet of Things (WF-IoT), pp. 706-711, 2018.
- [11] J. Joung, H. Kim, J. Park, H. Jung, "Night Time Leading Vehicle Detection Using Statistical Feature Based SVM," IEMEK J. Embed. Sys. Appl., Vol. 7, No. 4, pp. 163-172, 2012 (in Korean).
- [12] T. Park, Y. Moon, I. Eom, "Spliced Image Detection Using Characteristic Function Moments of Co-occurrence Matrix," IEMEK J. Embed. Sys. Appl., Vol. 10, No. 5, pp. 265-272, 2015 (in Korean).
- [13] R. E. Bellman, S. Dreyfus, Applied Dynamic Programming, Princeton Legacy Library, Princeton University Press, 2015.

Juneseo Chang (장 준 서)



He is currently a sophomore in Daegu Science High School. His research interests includes embedded software and deep learning.

Email: jschang0215@naver.com

Boguk Kim (김 보 국)



He is currently a sophomore in Daegu Science High School. His research interests includes networking and algorithm.

Email: boguk999@gmail.com

Changil Mun (문 창 일)



He is currently a sophomore in Daegu Science High School. His research interests includes ARM processor and Multicore processing.

Email: changilmoon@naver.com

Dohyun Lee (이 도 현)



He is currently a sophomore in Daegu Science High School. His research interests includes embedded programming and security.

Email: dhinvade1@naver.com

Junho Kwak (곽 준 호)



Junho Kwak received the B.S. degree in Electronics Engineering from Kyungpook National University (KNU), Daegu, Korea in 2019. He is currently

pursuing a integrated Ph.D. degree in Electronics Engineering at KNU. His research interest includes digital signal processing and embedded system.

Email: junho7513@gmail.com

Daejin Park (박 대 진)



He received the B.S. degree in electronics engineering from Kyungpook National University, Daegu, Korea in 2001, the M.S. degree and Ph.D.

degree in electrical engineering from the Korea Advanced Institute of Science and Technology (KAIST), Daejeon, Korea, in 2003, and 2014, respectively. He was a Research Engineer at Major Semiconductor Companies such as SK Hynix Semiconductor, Samsung Electronics over 12 years from 2003 to 2014, respectively and have worked on processor architecture design and low-power ASIC implementation with custom designed software algorithm optimization. Dr. Park is now with School of Electronics Engineering as full-time assistant professor in Kyungpook National University, Daegu, Korea and presidential research fellow.

Email: boltanut@knu.ac.kr

Yosoo Jeong (정 유 수)



Yosoo Jeong received the B.S. degree in mathematics from Kyungpook National University, Daegu, Korea in 2013, the M.S. degree and Ph.D.

degree in electronics engineering from KNU in 2015, and 2019, respectively. He is currently post-doctoral fellow in electronics engineering at KNU. His research interests includes embedded system and deep learning.

Email: ysjung@ee.knu.ac.kr